

Visualización de Modelos

Curvas ROC y AUC

Evaluación del rendimiento en Clasificación Binaria

¿Por qué la Exactitud nos engaña?

Clases Desbalanceadas

Si el 99% de tus datos son 'negativos' (ej. transacciones normales), un modelo que prediga siempre 'no' de forma perezosa logrará un 99% de exactitud (Accuracy).

Sin embargo, este modelo es completamente inútil para el negocio porque fallará al detectar el 1% de casos críticos positivos.

Umbral de Decisión

La métrica clásica de exactitud cambia drásticamente según el umbral de decisión elegido (por defecto 0.5).

Para problemas complejos, necesitamos evaluar el clasificador en todos los escenarios posibles, sin limitarnos a un único punto de corte.

Los Cimientos: Matriz de Confusión

Término	Definición	Resultado
VP (Verdadero Positivo)	El modelo predice positivo y realmente pertenece a esa clase.	Éxito de Captura
VN (Verdadero Negativo)	El modelo predice negativo y realmente pertenece a esa clase.	Descarte Correcto
FP (Falso Positivo)	Predicción positiva en un caso que es realmente negativo.	Falsa Alarma
FN (Falso Negativo)	Predicción negativa en un caso que es realmente positivo.	Fallo Crítico

Sensibilidad vs. Falsa Alarma

TPR (True Positive Rate)

También llamada Sensibilidad o Recall.

Indica la proporción de positivos reales que el modelo es capaz de detectar correctamente.

Fórmula matemática:

$$\text{TPR} = \text{VP} / (\text{VP} + \text{FN})$$

FPR (False Positive Rate)

Conocida como la tasa de Falsa Alarma.

Mide la proporción de casos reales negativos que el modelo clasifica de manera errónea como positivos.

Fórmula matemática:

$$\text{FPR} = \text{FP} / (\text{FP} + \text{VN})$$

El Mapa del Clasificador

¿Qué es la Curva ROC?

ROC: Receiver Operating Characteristic (Característica Operativa del Receptor).

Es una curva que evalúa el rendimiento del clasificador graficando la relación de TPR frente a FPR, mostrando la penalización de falsas alarmas que debemos admitir para mejorar la detección.

Representación Gráfica

- Eje Y: Muestra el ratio de éxitos TPR (Sensibilidad).
- Eje X: Muestra el ratio de falsas alarmas FPR.
- Se traza evaluando el comportamiento del clasificador en un espectro continuo de umbrales desde 1.0 hasta 0.0.

Dinámica de los Umbrales

Umbral 1.0 (Conservador)

No clasificamos nada como positivo. Cero falsas alarmas ($FPR = 0$), pero tampoco capturamos verdaderos positivos ($TPR = 0$). Nos situamos en el origen exacto $(0.0, 0.0)$.

Umbral 0.5 (Predeterminado)

Punto de balance intermedio estándar. Logra un equilibrio inicial entre tasa de éxitos de diagnóstico y costes de falsas alertas.

Umbral 0.0 (Permisivo)

Clasificamos todo como positivo automáticamente. Máxima detección ($TPR = 1.0$) a costa de arruinar el ratio de falsas alarmas ($FPR = 1.0$). Coordenada $(1.0, 1.0)$.

AUC: La Nota Final

0.85

Puntuación de Rendimiento
AUC

Área Bajo la Curva (AUC)

El AUC simplifica y resume todo el rendimiento de la curva ROC en un solo dato cuantitativo de diagnóstico.

Interpretación Clave:

Representa la probabilidad de que, al tomar de manera totalmente aleatoria un registro positivo y uno negativo, el clasificador asigne un valor de score predictivo mayor al positivo real.

Interpretando el Rendimiento

Rango de AUC	Clasificación	Estado en Producción
0.90 – 1.00	Excelente	Separación muy alta. Idóneo para entornos sensibles (salud, seguridad, finanzas).
0.80 – 0.90	Bueno	Estándar industrial de alto rendimiento. Resultados comerciales robustos.
0.70 – 0.80	Aceptable	Discriminación básica con margen claro de error. Requiere mayor optimización.
0.50	Sin Valor (Azar)	El modelo funciona igual de bien que lanzar una moneda común al aire.

Aplicaciones en el Mundo Real

Diagnóstico Médico

Buscamos una sensibilidad cercana al 100% para no ignorar enfermedades críticas reales, aceptando de forma preventiva un ratio mayor de falsas alarmas operativas.

Detección de Fraude

Ajustamos a un equilibrio donde podamos bloquear la mayor cantidad de robos sin saturar ni molestar a los clientes en sus compras legítimas cotidianas.

Seguridad (Antispam)

Fijamos un FPR cercano a 0%. Es preferible tolerar que un spam se cuele en la bandeja principal antes que arriesgarse a bloquear por error correos críticos.

Implementación en Python

```
from sklearn.metrics import roc_curve,  
roc_auc_score  
  
# PASO CRUCIAL: Utilizar probabilidades continuas  
y_probs = model.predict_proba(X_test)[: , 1]  
  
# Obtener el AUC global del modelo  
auc = roc_auc_score(y_test, y_probs)  
  
# Obtener los vectores para graficar la curva  
fpr, tpr, thresholds = roc_curve(y_test, y_probs)
```

¡Advertencia de Uso!

Nunca emplees la función estándar 'predict()' para evaluar la Curva ROC o el AUC.

Al entregar etiquetas binarias cerradas (0 o 1), el cálculo asumirá que cuentas únicamente con un umbral de decisión estático, generando una curva deformada e imprecisa.

Limitaciones y Advertencias

Desbalanceo Crítico

Si la clase positiva real es extremadamente infrecuente (ej. $< 0.5\%$), la tasa de Falsa Alarma (FPR) puede verse artificialmente baja e inmejorable.

En este contexto, se recomienda evaluar con las curvas Precision-Recall (PR) para no enmascarar deficiencias predictivas.

Costos de Error Asimétricos

La métrica del AUC trata un Falso Positivo exactamente con el mismo peso ponderado que un Falso Negativo.

En la práctica comercial, omitir un fraude (FN) o descartar una dolencia coronaria grave suele costar órdenes de magnitud más que causar falsas alarmas controladas.

¡Gracias!

Muchas gracias por vuestra atención.